四类任务真实试跑结果

这四题不足以给通用办公能力排总名次

完成40个有效候选单元：4个请求模型各用medium和max，先跑4题共32次，再对澄清后的B17各跑1次，共8次。关键金额、上线判断和未知项处理接近天花板；原分差异主要暴露了评分契约和解析器问题。

下表汇总独立AI辅助审阅。它不是模型排名，也不代表全部31题。模型名表示调用请求，工具未返回可独立核验的精确后端快照。

请求模型	思考档	B01 来源发现	B13 状态交接	B17 估值核对	B20 大表处理
6.1 Sol	medium	核验通过	核验通过	关键值通过	数据通过 视觉未知
6.1 Sol	max	核验通过	核验通过	关键值通过	数据通过 视觉未知
6 Sol	medium	核验通过	核验通过	关键值通过	数据通过 视觉未知
6 Sol	max	核验通过	核验通过	关键值通过	数据通过 视觉未知
6 Luna	medium	核验通过	核验通过	关键值通过 CSV错位	数据通过 视觉未知
6 Luna	max	核验通过	核验通过	关键值通过 列名问题	数据通过 视觉未知
5.6 Sol	medium	核验通过	核验通过	关键值通过	数据通过 视觉未知
5.6 Sol	max	核验通过	核验通过	关键值通过	数据通过 视觉未知

两处确定的普通产物问题

一份B17 CSV有16列表头但一条记录17个字段，造成字段错位；另一份把被排除的源行放进名为“ eligible ”的列。关键估值和UNKNOWN处理仍正确，这些问题不能被修复误罚时一起抹掉，也不应自动归为关键估值失败。

另1次B01启动尝试遇到跨执行会话的本机网络隔离，已作为INFRA单列排除；修通受控桥接后以全新会话重跑。

原始分数与澄清复测

原分完整保留 不能据此排行

数值为冻结RECON-0.1客观百分制。71.43或76.47并不表示对应业务结果错误：金额写法、隐藏列契约、文本类型等会造成误罚。

请求配置	B01	B13	B17	B20
6.1 Sol medium	91.67	91.67	77.14	76.47
6.1 Sol max	91.67	91.67	71.43	76.47
6 Sol medium	91.67	91.67	71.43	100.00
6 Sol max	91.67	91.67	71.43	76.47
6 Luna medium	91.67	91.67	71.43	100.00
6 Luna max	91.67	91.67	77.14	100.00
5.6 Sol medium	91.67	91.67	77.14	100.00
5.6 Sol max	91.67	91.67	77.14	76.47

B17澄清后的8次新会话

同一业务输入，只公开EUR目标、期间标签和CSV规则；八份CSV都符合固定五列要求。这是修订验证，不是独立能力确认集。

请求配置	新客观分	独立AI审阅结论
6.1 Sol medium	100.00	事实 完整性 可用性 4 / 4 / 4
6.1 Sol max	100.00	事实 完整性 可用性 4 / 4 / 4
6 Sol medium	100.00	事实 完整性 可用性 4 / 4 / 4
6 Sol max	100.00	事实 完整性 可用性 4 / 4 / 4
6 Luna medium	UNKNOWN	核心值正确；映射范围仍有歧义
6 Luna max	100.00	事实 完整性 可用性 4 / 4 / 4
5.6 Sol medium	100.00	事实 完整性 可用性 4 / 4 / 4
5.6 Sol max	100.00	事实 完整性 可用性 4 / 4 / 4

一个输出在selected_*中附上真实、但SGD仍UNKNOWN的源行。“ 已确认 ”未明确绑定SGD状态，故终裁保留UNKNOWN；没有为了制造差分将其定为确定模型错误。

修复范围与留下的边界

修复评分公平性 同时保留真实错误

问题	修订口径
主体字段与状态证据	接受有依据的字段别名、集合顺序及相关支持来源。错误身份字段、缺权威证据仍须失败。
金额与期间标签	有限Decimal数值等价，period等真实源字段不再因隐藏写法失分。错误金额、NaN、错期间仍失败。
旧B17字段与CSV欠定义	旧EUR标量口径和未公开列契约记UNKNOWN，保留逐项语义审核；真实CSV错列仍单独FAIL。
新B17公开规则	固定EUR对象、公开期间词表和五列CSV。额外汇总或“已确认”范围仍不能唯一解释时保留UNKNOWN。
XLSX文本类型	识别str、s、inlineStr。真实数字化、前导0丢失或金额写成文本仍拒绝。
XLSX公式	验证受支持的实际公式、缓存及源数据。未覆盖合法公式保留UNKNOWN，不能只凭缓存通过。
来源服务与版本身份	旧观测只在旧包身份验证后回算；新运行使用新包fingerprint与独立session，不重写旧证据。

实际文件证据

两份工作簿另经LibreOffice实际导入导出复核，其中一份包含2400个ROUND公式。2401行×6列的值与类型均无变化；这支持具体文件的数据/计算正确性，不等于已完成所有视觉或Microsoft Excel兼容验证。

OpenXML的str是字符串类型，见 Microsoft CellValues官方文档。

真实缺陷和未知项都保留

基线AI审阅：31份事实维度为4，1份为3；8份Office视觉/整体可用性仍未知。澄清复测：7份三个维度均4；1份事实4，完整性和可用性未知。没有真人评分，也没有把UNKNOWN补0或补满分。

结论与复核入口

本轮可以得出的结论

这四个历史压力变体更适合作为基础可靠性检查。它们能暴露部分表格交付瑕疵，但本轮未建立通用办公整体能力排名，亦不能稳定区分四个模型或medium与max。修复后的评分应先用于把“真错”和“测不清”分开。

下一轮应先覆盖通用办公能力，在运行前固定题型、难度、权重和重复次数，保留独立确认题。当前题中的CURRENT等行ID提示、很短的来源集合及显式状态线索，可能降低难度；这一点是待验证假设。本轮不为制造差分追加更难题。

旧输出最终回算：B01/B20共16份完整客观100；B13/B17共16份整体UNKNOWN，已知权重均正确，分别覆盖22/24及27/35或29/35。真实CSV错列另留FAIL。局部正确率100不能当作整体满分。

方法与限制

每个配置/题目仅1次；无统计显著性、稳定排名或thinking因果结论。

候选独立新会话，只给单题导出和自己的输出目录；共享宿主仅有目录指令限制，不是已验证OS安全盲测。服务查询有独立日志，本地读取主要为自报。

相同题目的输入文件hash一致。最初两个保留单元的调度说明较长，题内prompt/schema及实质权限相同，但包装文字并非全部逐字一致。

token、费用、种子、精确模型快照未由工具返回，统一UNKNOWN。记录的墙钟时间含工具、排队、并发，不能作为纯推理速度。

附件与可复核证据

baseline_matrix.csv：32个基线单元、原分、AI维度、状态和证据引用。

comparison_matrix.csv：原分、旧输出语义回算、新B17结果分开列示。

evaluator/baseline-evidence-manifest.json：570份基线文件hash；revisions/B17-contract-0.2/candidate-evidence-manifest.json：8次复测输入/产物hash。

evaluator/regrade_baseline.py与其adapter-controls.json：旧证据绑定、检查级改动、欠定义UNKNOWN及真实错列控制。

blind-review与blind-review-v2：匿名独立AI审核、证据和异议修订记录。正式RECON-0.2包另附使用说明、测试与冻结清单。

基线清单 b2482a51843fa…；B17固定澄清契约 a1eb635d8edc…；完整hash保存在上述证据文件中。

怎样比较通用办公能力

目前不能据此选出可靠赢家

本轮关键业务结果接近天花板，只有两处普通产物问题。它们值得保留，但单次样本不足以推断某个模型一贯更差，或max一定优于medium。主目标是比较通用办公整体质量；业务分项其次。速度独立报告，成本不混入能力排名。

速度有记录 还不能做纯速度排名

基线32次记录的编排观察区间为53.88 – 437.10秒，中位123.43秒；澄清8次为110.53 – 256.03秒，中位178.86秒。两批条件与任务不同，不能解释为提速或变慢。

开始是编排层邻近提交时的手填时间，结束是完成回报后、评估器准备评分的收件时间；不包含随后评分和盲审。没有统一供应商开始、首token、最后token或独立完成事件。排队、工具、并发与收件延迟混在一起；B01桥接只有完成事件at，连单次HTTP耗时也不能可靠分拆。

评分需要更细吗？

现有四题已有11 – 15个客观检查，另有0 – 4级AI审阅；主要瓶颈不是小数位不够，而是隐藏规则、部分语义缺乏可判边界，以及任务本身偏容易。可把事实、覆盖、证据、交付格式、视觉和行动边界分别记录，但只有证据支持的差异才该扣分。

下一轮预先固定的改进方向

建议下一轮覆盖优先：8配置×6类×每类2个不同新实例×1次，共96次，可分两批。另留未见确认实例；对临界/波动任务再预先限定对称重复。这仍是小型初步比较，尚未启动。

先固定六类覆盖：证据检索整合、数据分析、文档/演示、多约束编辑、多步执行、异常恢复。业务特定任务作为其次的分项。

预先确定各能力维度的权重、质量门槛和总分合成办法，调参题与确认题分开；用重复试验报告不确定性，证据不足时允许并列。

能力榜只基于质量证据。速度另列并补统一计时；费用和tokens即使将来可得，也不进入“能力最强”的质量排名。

不因本轮没拉开差距而临时加难或制造细碎扣分。先保证评分测的确实是通用能力，再看确认集是否提供稳定信号。

完整时序逐单元记录与方法说明见 selection-signal.json / selection-signal.md。